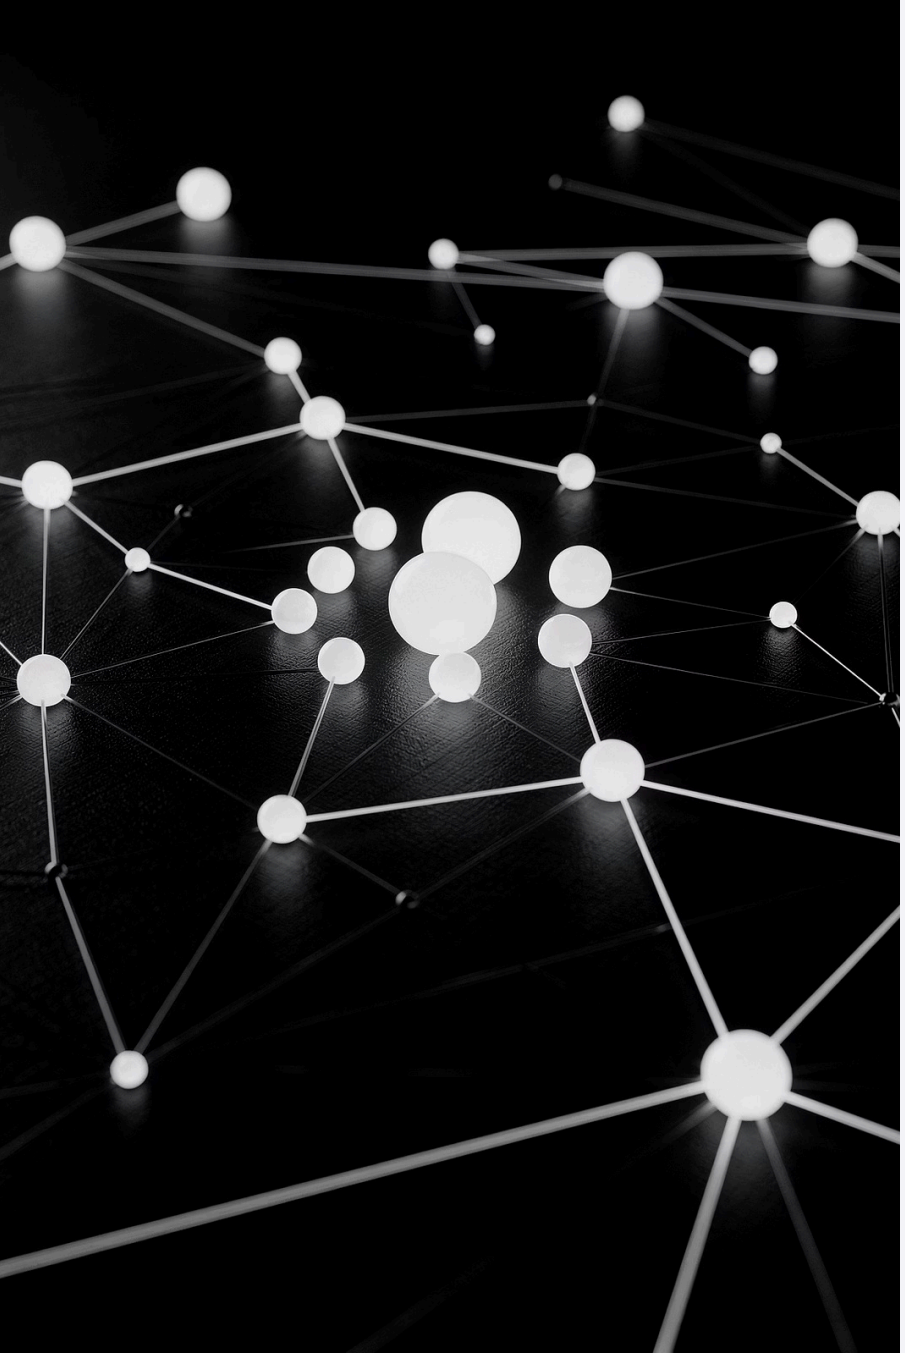

Economía conductual en el ecosistema algorítmico

Cuando la teoría de Simon, Kahneman, Tversky y Thaler se encuentra con los sistemas de recomendación, los modelos de decisión automatizada y la arquitectura algorítmica de elecciones. Un recorrido formal por la anatomía cognitiva del *homo oeconomicus digitalis* —con taxonomía de sesgos, evidencia empírica y aplicaciones PropTech.

DR. LEONARDO GONZÁLEZ TEJEDA

ITESM · EGADE · HOMEPTY RESEARCH

BEHAVIORAL ECON × ALGOGOV

ED. 2026 · CDMX

CONTENIDO DEL MÓDULO

Estructura del módulo

Este módulo especial integra formalización matemática, evidencia empírica y aplicaciones algorítmicas de la economía conductual. El recorrido sigue una lógica acumulativa: de los fundamentos teóricos a las implicaciones regulatorias y a las aplicaciones sectoriales en PropTech.

01

Marco teórico

De la racionalidad limitada (Simon, 1955) al hypernudge algorítmico (Yeung, 2017). Fundamentos del programa conductual.

02

Formalización matemática

Teoría de perspectivas acumulativa (CPT), función de ponderación w(p) y descuento hiperbólico β-δ.

03

Arquitectura algorítmica

Nudges, hypernudges, sistemas de recomendación, dark patterns y amplificación de sesgos.

04

Evidencia y regulación

Estudios seminales con efectos cuantificados, marco normativo emergente y aplicaciones PropTech.

§1 MARCO TEÓRICO

De la racionalidad limitada al sistema socio-técnico algorítmico

La economía conductual nació como una corrección empírica de la axiomática neoclásica; el ecosistema algorítmico la convierte, dos generaciones después, en una tecnología operativa de poder sobre la decisión —y en un objeto urgente de regulación.

El programa conductual: hitos fundacionales

En **1955**, Herbert Simon introdujo la **racionalidad limitada** (*bounded rationality*) como respuesta al agente maximizador de la teoría de utilidad esperada: los humanos no optimizan, *satisfacen*; no computan distribuciones, *usan heurísticas*. Dos décadas después, **Tversky y Kahneman (1974)** formalizaron tres heurísticas —disponibilidad, representatividad y anclaje— que dieron cuerpo empírico al programa. La **teoría de perspectivas** (1979) y su versión acumulativa (1992) culminaron el andamiaje matemático, mientras **Thaler y Sunstein (2008)** lo tradujeron en un dispositivo normativo: la *arquitectura de elecciones*.

El giro algorítmico: instrumentalización del andamiaje

El giro algorítmico del siglo XXI no desmonta ese andamiaje: lo **instrumentaliza**. Los sistemas de recomendación, los motores de *dynamic pricing*, los *feeds* curados por aprendizaje automático y las interfaces de e-commerce constituyen hoy la *arquitectura de elecciones por defecto* de miles de millones de decisiones diarias —y explotan, de forma endógena y a menudo no supervisada, las mismas debilidades cognitivas que la literatura conductual identificó.

Karen Yeung (2017) acuñó el término **hypernudge** para capturar esta mutación: no se trata ya de un nudge estático, sino de uno **dinámico, personalizado y reactivo** —alimentado por datos conductuales en tiempo real.

> "El mercado, cuando está mediado por algoritmos que aprenden de nuestras propias debilidades, no es ya un árbitro neutral entre preferencias: es una tecnología de formación de preferencias." — Adaptación de Yeung (2017) y Sunstein (2019)

§1 MARCO TEÓRICO

Métricas canónicas del programa conductual

Los parámetros que se muestran a continuación constituyen las calibraciones de referencia de la Teoría de Perspectivas Acumulativa (CPT) y han sido replicados en decenas de estudios desde su publicación original. Representan, en conjunto, la huella matemática de la irracionalidad sistemática del agente económico real.

≈2.25λ

Aversión a la pérdida

Coeficiente de aversión a la pérdida (mediana empírica). Una pérdida de $100 genera un malestar psicológico equivalente al bienestar de una ganancia de $225. Tversky & Kahneman, 1992.

0.88α,β

Curvatura del valor

Parámetros de curvatura en ganancias (α) y pérdidas (β). α < 1 implica concavidad en ganancias (aversión al riesgo); β < 1 implica convexidad en pérdidas (búsqueda de riesgo). CPT, calibración clásica.

0.61γ

Ponderación probabilística

Elasticidad de la función de ponderación en el dominio de ganancias. Captura la sobreponderación sistemática de eventos raros y la subponderación de eventos frecuentes. Tversky & Kahneman, 1992.

70%

Recomendación algorítmica

Proporción de reproducciones en YouTube originadas por el sistema de recomendación algorítmico, no por búsqueda activa del usuario. Ilustra la escala del hypernudge contemporáneo. Pew Research, 2018.

§2 TAXONOMÍA DE SESGOS

Doce piedras angulares del comportamiento económico

Una clasificación operativa de los sesgos más robustamente documentados, con su manifestación algorítmica correspondiente. La selección obedece a tres criterios: **(i)** robustez metaanalítica, **(ii)** relevancia para decisiones económicas y **(iii)** evidencia documentada de explotación algorítmica. El **Cognitive Bias Codex** (Manoogian & Benson, 2016) documenta más de 180 sesgos, muchos de los cuales son reformulaciones o interacciones de los aquí presentados.

Anclaje

El primer valor presentado actúa como referencia que distorsiona estimaciones posteriores. En precios dinámicos: el precio "tachado" es el ancla.

Aversión a la pérdida

Las pérdidas duelen ~2.25× más que el placer equivalente de una ganancia. Base de los mensajes de escasez y urgencia algorítmica.

Sesgo de disponibilidad

La facilidad de recuperación de un evento desde la memoria infla su probabilidad percibida. Los feeds algorítmicos controlan qué información es "disponible".

Efecto por defecto

Las opciones pre-seleccionadas capturan desproporcionadamente la elección. El algoritmo decide cuál es el default; Madrian & Shea (2001) documentan un salto de 49% a 86% en participación en planes de ahorro.

Sesgo del presente

Preferencia desproporcionada por recompensas inmediatas sobre futuras. Modelo β-δ (Laibson, 1997): $\beta \approx 0.7$ en estimaciones típicas. Base del BNPL y las ofertas "compre ahora".

Prueba social

"12 personas están viendo este producto." La incertidumbre dispara la imitación. Los sistemas de recomendación son mecanismos de prueba social computacional a escala masiva.

Sesgo de confirmación

Tendencia a buscar, interpretar y recordar información congruente con las creencias previas. Los algoritmos de engagement maximizan confirmación, generando echo chambers.

Efecto de encuadre

La misma información presentada como ganancia o pérdida genera decisiones radicalmente distintas. El copywriting algorítmico explota el encuadre a escala individual.

Ilusión de control

Sobrestimación del grado de influencia personal sobre resultados aleatorios. Plataformas de trading y betting algorítmico la amplifican con interfaces de "personalización".

Representatividad

Juicios de probabilidad basados en similitud con prototipos, ignorando tasas base. Los motores de búsqueda refuerzan estereotipos al ordenar resultados por relevancia percibida.

Choice overload

El exceso de opciones paraliza o degrada la calidad de la decisión (Iyengar & Lepper, 2000). Los algoritmos de filtrado "solucionan" el problema, ganando poder de curaduría.

Efecto de dotación

Las personas valoran más los bienes que ya poseen. Pruebas gratuitas, carritos de compra pre-llenados y suscripciones con periodos de gracia explotan este sesgo.

La función de valor S-shape: aversión a la pérdida formalizada

Kahneman y Tversky demostraron que el agente real no evalúa estados terminales de riqueza sino *variaciones* respecto de un punto de referencia —y que las pérdidas duelen, en promedio, 2.25 veces más que el placer equivalente que aportan las ganancias. Este hallazgo, publicado en *Econometrica* (1979) y refinado en la versión acumulativa de 1992, constituye la piedra angular de toda la economía conductual posterior.

Función de valor CPT

La función de valor de la Teoría de Perspectivas Acumulativa (Tversky & Kahneman, 1992) toma la siguiente forma:

$$v(x) = \begin{cases} x^{\alpha} & x \geq 0 \\ -\lambda(-x)^{\beta} & x < 0 \end{cases}$$

Parámetros canónicos: α ≈ β ≈ 0.88 (curvatura cóncava en ganancias, convexa en pérdidas); λ ≈ 2.25 (coeficiente de aversión a la pérdida).

- **α < 1** → concavidad en ganancias: aversión al riesgo en el dominio positivo
- **β < 1** → convexidad en pérdidas: búsqueda de riesgo en el dominio negativo
- **λ > 1** → la función es más empinada en pérdidas que en ganancias

Implicaciones conductuales y algorítmicas

La forma en S de la función de valor genera predicciones contraintuitivas respecto del modelo de utilidad esperada: los agentes son aversos al riesgo en el dominio de las ganancias (prefieren una ganancia segura de $X a una lotería con valor esperado $X) pero buscadores de riesgo en el dominio de las pérdidas (prefieren una lotería con valor esperado −$X a una pérdida segura de $X).

Esta asimetría tiene implicaciones directas para el diseño algorítmico. Plataformas de e-commerce que enmarcan sus descuentos como *"evita perder esta oferta"* en lugar de *"obtén este descuento"* explotan el dominio de pérdidas para incrementar la propensión de compra. Los sistemas de CRM adaptativos aprenden, mediante aprendizaje por refuerzo, qué encuadre maximiza la conversión para cada segmento psicográfico.

La calibración original (Kahneman & Tversky, 1979) se realizó con ~150 participantes universitarios en Israel. El meta-análisis de Walasek & Stewart (2015) sobre 150 estudios posteriores muestra que λ varía entre 1.4 y 4.0 dependiendo del dominio, magnitud de las apuestas y contexto cultural.

La función w(p): por qué compramos lotería y seguros a la vez

Los agentes no tratan las probabilidades de manera lineal. Eventos raros (p pequeña) son **sobreponderados**; probabilidades moderadas y altas, **subponderadas**. La función *w(p)* captura esta distorsión sistemática y explica fenómenos aparentemente contradictorios en el comportamiento financiero y de consumo.

$$w(p) = \frac{p^\gamma}{\left(p^\gamma + (1-p)^\gamma\right)^{1/\gamma}}$$

Formulación de Tversky & Kahneman (1992). Parámetros estimados: **$\gamma^+ \approx 0.61$** (ganancias), **$\gamma^- \approx 0.69$** (pérdidas). La función alternativa de Prelec (1998) es $w(p) = \exp(-(-\ln p)^\gamma)$, que satisface propiedades adicionales de coherencia probabilística.

El puzzle de Allais y la curva invertida en S

Con γ = 0.61, una probabilidad objetiva de 1% es percibida subjetivamente como aproximadamente **6.2%**. Esto explica directamente por qué las loterías son económicamente irracionales pero masivamente adoptadas: los compradores "sienten" que su probabilidad de ganar es seis veces mayor de lo que es. En el extremo opuesto, probabilidades del 90% se perciben como si fueran del ~80%, generando subponderación de certezas casi absolutas.

El **efecto Allais** (1953) fue la primera anomalía documentada respecto al axioma de independencia de la teoría de utilidad esperada de Von Neumann-Morgenstern. La función w(p) provee su explicación formal cuatro décadas después.

Explotación algorítmica de w(p)

La distorsión w(p) sostiene fenómenos aparentemente contradictorios: el mismo individuo compra un **billete de lotería** (sobreponderando la minúscula probabilidad de ganar) y una **póliza de seguros** contra un evento improbable (sobreponderando la minúscula probabilidad de catástrofe). En el ecosistema algorítmico:

- **Mercados de predicción** y apuestas deportivas en vivo amplifican la sobreponderación de eventos raros mediante interfaces de "jackpot en tiempo real"
- **Trading de opciones binarias** en plataformas gamificadas explota γ < 1 en usuarios con baja literacidad financiera
- **Microapuestas integradas** en videojuegos (loot boxes) han sido reguladas en Bélgica y Países Bajos bajo legislación de juego de azar
- **Seguros de pantalla** ofrecidos en checkout de e-commerce explotan la sobreponderación de la probabilidad de daño

§5 DESCUENTO HIPERBÓLICO

El sesgo del presente: por qué el yo de hoy traiciona al yo de mañana

La teoría neoclásica asume descuento exponencial (δ^t), lo que implica preferencias temporales consistentes. Pero la evidencia experimental y de campo muestra descuentos hiperbólicos: el agente es fuertemente impaciente a corto plazo y relativamente paciente a largo plazo —una **inconsistencia dinámica** que Laibson (1997) formalizó como el modelo β-δ.

Los tres modelos de descuento

$$D_{\exp}(t) = \delta^t \qquad D_{\text{hip}}(t) = \frac{1}{1+kt} \qquad D_{\beta\text{-}\delta}(t) = \begin{cases} 1 & t = 0 \\ \beta\delta^t & t > 0 \end{cases}$$

El modelo cuasi-hiperbólico β-δ de Laibson (1997) captura la discontinuidad entre el presente (t=0) y cualquier momento futuro (t>0). Estimaciones empíricas típicas: **β ≈ 0.70** (sesgo presente), **δ ≈ 0.96** (paciencia a largo plazo), **k ≈ 0.25** (tasa hiperbólica).

Explotación algorítmica del descuento hiperbólico

El ecosistema de consumo digital ha sido diseñado, en gran medida, para explotar la curvatura β-δ. Los mecanismos más documentados incluyen:

- **Contadores regresivos** ("Oferta termina en 00:14:37"): precipitan la decisión hacia el presente, reduciendo efectivamente el peso del yo futuro
- **Buy Now Pay Later (BNPL)**: Klarna, Afterpay y similares desplazan el costo al futuro, explotando β < 1 para reducir el dolor percibido del gasto actual
- **Infinite scroll y autoplay**: eliminan la fricción del punto de parada, secuestrando la decisión de "siguiente episodio" al momento presente de menor resistencia
- **Notificaciones push**: crean urgencia artificial que eleva la tasa de descuento efectiva del usuario en el momento de la notificación
- **Periodos de gracia en suscripciones**: la "prueba gratis de 30 días" explota que el yo de hoy no internaliza el costo que pagará el yo del futuro

⚠ La **inconsistencia dinámica** implica que los agentes se arrepienten de sus elecciones pasadas. DellaVigna & Linos (2022) estiman que los nudges que explotan el sesgo del presente tienen efectos significativamente mayores en el laboratorio que en el campo, sugiriendo habitualización parcial.

De los nudges de Thaler a los hypernudges algorítmicos

Un *nudge* —en la definición canónica de Thaler y Sunstein (2008)— es cualquier aspecto de la arquitectura de elección que altera el comportamiento de forma predecible sin prohibir opciones ni alterar sustancialmente los incentivos económicos. El algoritmo lo convierte en un dispositivo dinámico, personalizado y de escala masiva cuya naturaleza normativa es radicalmente distinta.

1

Nudge clásico

Estático · Universal

Una opción por defecto (p. ej. inscripción automática en planes de pensión), un orden de cafetería que favorece fruta, una etiqueta nutricional en semáforo. El mismo nudge para todos los agentes, en todos los contextos, de forma transparente y auditaable. Thaler & Sunstein (2008).

2

Nudge personalizado

Individualizado · Reactivo

Recomendaciones ajustadas al perfil psicográfico (Big-Five) del usuario, *copy* generado dinámicamente para maximizar *click-through*, descuentos que aparecen cuando el cursor se aleja del botón "comprar". La personalización requiere inferencia de rasgos desde datos conductuales. Matz et al. (2017), PNAS.

3

Hypernudge

Dinámico · Continuo · Opaco

Feeds algorítmicos que recomponen la arquitectura de elección en cada *refresh*, en función del comportamiento del usuario **y de millones de otros usuarios**. Opacidad estructural: el agente no puede conocer qué nudge recibe ni compararlo con el de otros. Yeung (2017).

La física de la elección: Ley de Hick–Hyman

La **Ley de Hick–Hyman** (Hick, 1952; Hyman, 1953) establece que el tiempo de reacción en una decisión crece logarítmicamente con el número de alternativas equiprobables:

$$RT = a + b \cdot \log_2(n+1)$$

Empíricamente, b ∈ [150, 200] ms/bit en decisiones visuales. Para n = 8 alternativas con b = 150 ms/bit: **RT ≈ 450 ms**.

En interfaces algorítmicas esto implica que **la curaduría es una forma de poder**: reducir las n opciones visibles no sólo acelera la decisión, la **altera sistemáticamente**. El algoritmo que decide cuántas y cuáles opciones son presentadas al usuario controla, en términos de Hick-Hyman, el espacio cognitivo disponible para la deliberación.

> "Cuando la arquitectura de elecciones es algorítmica, dinámica y opaca, la línea entre *libertarian paternalism* y manipulación se vuelve conceptualmente indefendible." — Parafraseando a Sunstein (2019)

El efecto Mateo computacional: cómo el algoritmo amplifica sesgos

Los sistemas de recomendación introducen una retroalimentación positiva entre exposición, adopción y recomendación futura —un proceso stigmérgico que amplifica sesgos preexistentes y genera polarización, *filter bubbles* y homofilia algorítmica. La formalización permite entender cómo la lógica interna del collaborative filtering produce desigualdad estructural en el consumo de información y bienes.

$$p_{i,t+1}(a) = \underbrace{\lambda \cdot u_{i,t}(a)}_{\text{preferencia propia}} + \underbrace{(1-\lambda) \cdot s(\mathbf{N}_i, a, t)}_{\text{señal algorítmica}}, \qquad s \propto \sum_{j \in \mathbf{N}_i} p_{j,t}(a)$$

Cuando λ es bajo, la decisión del agente i en t+1 está dominada por las decisiones pasadas de su vecindario computacional $\mathbf{N_i}$. La homofilia emerge como atractor dinámico. Ver Pariser (2011); Nguyen et al. (2014).

Efecto Mateo algorítmico

"Al que tiene se le dará" (Mt 25, 29). En sistemas de recomendación, la probabilidad de ser recomendado es proporcional al número previo de exposiciones. Esto genera **distribuciones power-law** con coeficiente de Gini típico > 0.9: un pequeño conjunto de contenidos captura la mayor parte de la atención agregada del sistema.

Filter bubble y homofilia

Pariser (2011) argumentó que la personalización algorítmica reduce la exposición a información disonante. Sunstein (2017) añade que esto erosiona el *common ground* deliberativo. La evidencia empírica es, sin embargo, heterogénea: Bakshy et al. (*Science*, 2015) estiman que en Facebook el sesgo está más en la **selección del usuario** que en el algoritmo propiamente dicho.

Popularity bias y equidad

El sistema sobre-recomienda ítems ya populares, perpetuando la desigualdad del catálogo. Afecta con especial intensidad a editoriales, música independiente y plataformas de streaming. Los nuevos entrantes (cold-start) carecen de señales y reciben prioridad baja, comprometiendo la equidad competitiva y creando barreras de entrada informacionales.

La industrialización de la manipulación cognitiva

Patrones de interfaz diseñados deliberadamente para inducir decisiones contrarias al interés del usuario. Mathur et al. (2019) auditaron **11,000 sitios de comercio electrónico** mediante crawl automatizado y encontraron **1,818 instancias de 15 tipos distintos** de dark patterns en 1,254 sitios —el **11.1% de la muestra**. Luguri & Strahilevitz (2021) demostraron mediante RCT que la exposición a dark patterns aumenta la aceptación de ofertas indeseadas en un factor de **2.2×** incluso bajo exposición leve.

Escasez artificial

Countdown timer / Low-stock message. Temporizadores falsos o artificiales que invocan urgencia ("Oferta termina en 00:02:47") y mensajes de stock fabricados o no verificables ("¡Sólo quedan 2 habitaciones!"). Explotan la aversión a la pérdida y el sesgo del presente simultáneamente.

Prueba social fabricada

Activity messages. Notificaciones de actividad que no pueden ser auditadas ni verificadas por el usuario ("12 personas están viendo este producto ahora"). Explotan la heurística de representatividad y la prueba social (Cialdini). La API de datos en tiempo real permite generarlas dinámicamente.

Roach motel y continuidad forzada

Forced continuity / Roach motel. Suscripciones que inician tras un periodo gratuito sin aviso suficiente (forced continuity). Estructuras donde suscribirse es trivial pero cancelar requiere llamar por teléfono, formularios complejos o períodos de espera (roach motel). Asimetría deliberada de fricción.

Coerción emocional y engaño visual

Confirm shaming / Visual interference / Misdirection. El rechazo se formula para inducir culpa ("No, prefiero pagar precio completo"). La jerarquía visual esconde la opción pro-usuario (botón "rechazar cookies" 4× más pequeño). Pre-selección silenciosa de seguros en checkout sin consentimiento explícito.

⚠ La **FTC** (EEUU), el **Digital Services Act** (DSA, UE 2022) y la **ley francesa SREN** (2024) han comenzado a tipificar los dark patterns como prácticas desleales. La evidencia económica (Luguri & Strahilevitz, 2021) muestra efectos causales significativos incluso bajo exposición leve, lo que justifica una respuesta regulatoria ex ante en lugar de ex post.

§9 EVIDENCIA EMPÍRICA

Estudios seminales con efectos cuantificados

Una selección de investigaciones de referencia con tamaño muestral, efecto reportado y DOI verificable. La validez externa de la economía conductual es objeto de debate vivo: la Open Science Collaboration (2015) replicó con éxito sólo el 39% de los estudios psicológicos originales. El meta-análisis de **DellaVigna & Linos (2022)** en *Econometrica* revela que los efectos de nudges publicados en la literatura académica son **~6 veces mayores** que los observados en Nudge Units gubernamentales —una brecha de publicación que exige cautela bayesiana en la extrapolación.

Estudio	n	Tema	Efecto principal	DOI
Kahneman & Tversky (1979) Econometrica	~150	Prospect Theory	$\lambda \approx 2.25$	10.2307/1914185
Tversky & Kahneman (1992) J. Risk Uncertainty	25×2	CPT acumulativa	$\alpha = \beta = 0.88$	10.1007/BF00122574
Madrian & Shea (2001) QJE	~200,000	Default effect 401(k)	Inscripción 49% → 86%	10.1162/0033553017532 65543
Thaler & Benartzi (2004) JPE	3,500	SMarT program	Ahorro 3.5% → 13.6%	10.1086/380085
Matz, Kosinski et al. (2017) PNAS	3.5M impresiones	Psychological targeting	CTR +40%; conv. +50%	10.1073/pnas.1710966114
Mathur et al. (2019) CSCW	11,000 sitios	Dark patterns crawl	11.1% con al menos un DP	10.1145/3359183
Luguri & Strahilevitz (2021) J. Legal Anal.	1,963 (RCT)	Efecto causal dark patterns	Aceptación ×2.2	10.1093/jla/laaa006
DellaVigna & Linos (2022) Econometrica	126 RCTs	Meta-análisis nudges campo	Efecto 1.4pp (vs 8.7pp acad.)	10.3982/ECTA18709
Bakshy, Messing & Adamic (2015) Science	10.1M usuarios	Filter bubble Facebook	Algoritmo < selección usuario	10.1126/science.aaa1160
Allcott et al. (2020) AER	2,743	Welfare effects Facebook deact.	Bienestar $+0.09\sigma$	10.1257/aer.20190658
Mullainathan & Shafir (2013)	~3,000	Escasez cognitiva	Caída CI 13 pts bajo escasez	10.1126/science.1238041

Nota metodológica crítica. El meta-análisis de DellaVigna & Linos (2022) revela una *brecha de publicación* significativa: los efectos de los nudges publicados en la literatura académica son ~6 veces mayores que los observados en Nudge Units gubernamentales de EEUU y Reino Unido. Esto sugiere que la extrapolación directa de hallazgos conductuales a la política pública debe hacerse con cautela bayesiana y diseño de poder estadístico adecuado.

§9 EVIDENCIA EMPÍRICA

La brecha de publicación en nudges: laboratorio vs. campo

El hallazgo de DellaVigna & Linos (2022) merece un análisis detallado dado su impacto sobre la credibilidad del programa conductual aplicado. Los autores analizan 126 RCTs conducidos por las Nudge Units de EEUU (Social and Behavioral Sciences Team) y Reino Unido (Behavioural Insights Team), comparándolos sistemáticamente con el corpus académico publicado.

Contexto

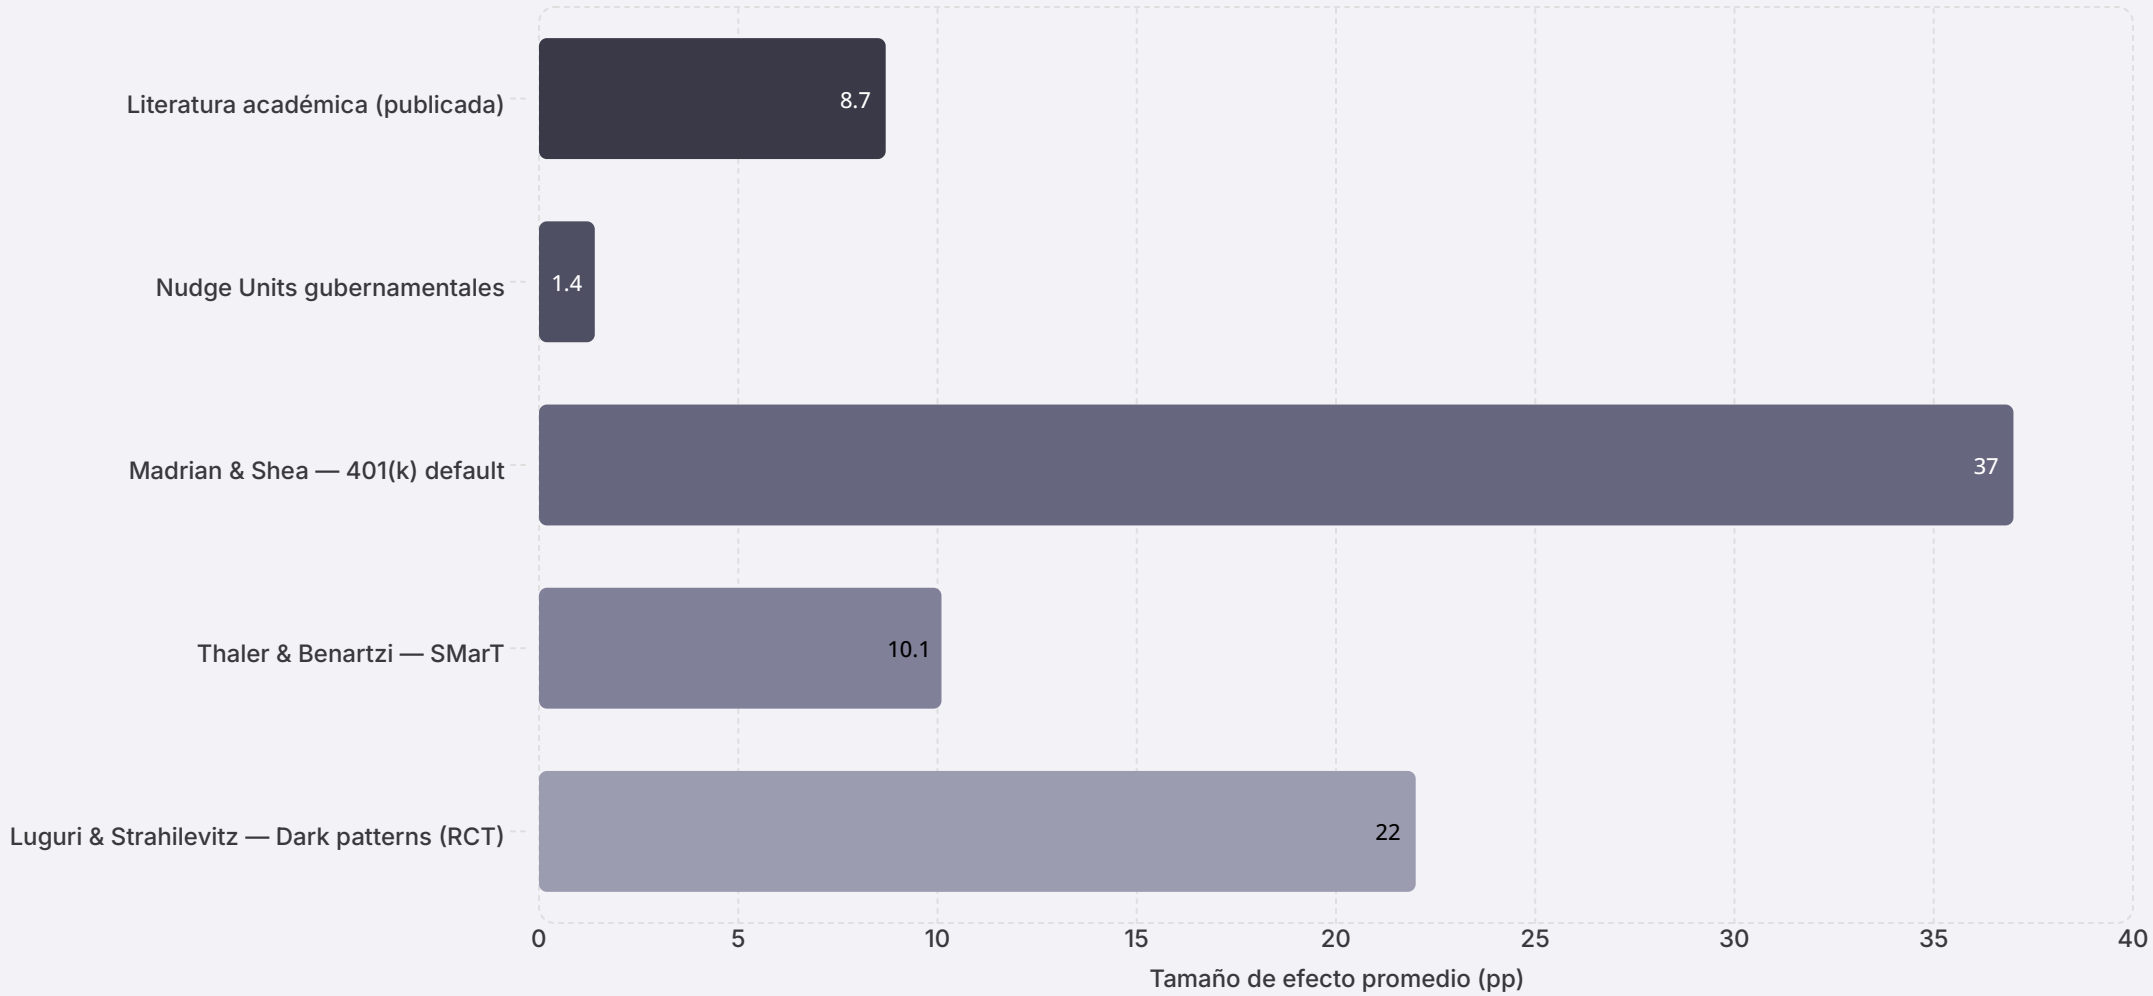

La brecha (8.7pp vs. 1.4pp) refleja una combinación de sesgo de publicación, heterogeneidad de los contextos de aplicación y habitualización de los agentes a los nudges. Esto no invalida el programa conductual, pero sí demanda mayor rigor en el diseño de intervenciones de política pública y en las afirmaciones sobre escalabilidad de los efectos.

§10 PROPTECH APLICADO

Economía conductual en el mercado inmobiliario digitalizado

El mercado de vivienda concentra las condiciones óptimas para la amplificación de sesgos: decisiones de alta magnitud, baja frecuencia, elevada asimetría de información, intangibilidad del bien durante la búsqueda y mediación algorítmica creciente en toda la cadena de valor. La elasticidad ingreso de la demanda por vivienda documentada para México (González Tejeda & Adamuz, 2016; $\theta \approx 0.98$) opera dentro de este marco conductual, no en el vacío clásico.

1

Fijación de precio — Anclaje

El primer precio listado ancla las expectativas de compradores y vendedores. Los **Automated Valuation Models (AVMs)** pueden reforzar el anclaje si toman el precio listado como predictor, creando circularidad endógena: el AVM aprende del precio anclado, que a su vez se valida por el AVM. González Tejeda (WP-2026-DVH) lo denomina "punto fijo dinámico del sistema".

2

Búsqueda y filtrado — Hick-Hyman

Portales con >10,000 listados obligan al uso de filtros algorítmicos. El orden de resultados —aparentemente neutral— determina **>80% de las visitas físicas efectivas**. La curaduría algorítmica es, en términos de Hick-Hyman, una restricción cognitiva que redefine el conjunto de elección del comprador.

3

Negociación — Aversión a la pérdida

Propietarios exhiben precios de reserva **20-30% por encima** del valor fundamental estimado por AVM cuando enfrentan una pérdida nominal (Genesove & Mayer, 2001). Las plataformas que muestran "cambio respecto al precio inicial" construyen explícitamente el marco de reference dependence que activa la aversión a la pérdida.

4

Financiamiento — Sesgo del presente

Ofertas "hipoteca fácil" con CAT oculta, mensualidades crecientes o periodos de gracia explotan el descuento hiperbólico. El **CUCR** (Costo de Uso del Capital Residencial) ofrece una medida normativa neutralizada que permite comparaciones intertemporales coherentes, independientemente del encuadre del oferente.

Caso canónico: Genesove y Mayer (2001)

Este estudio constituye una de las evidencias más robustas de aversión a la pérdida en mercados reales —no experimentales— y es de lectura obligatoria en cualquier curso de economía conductual aplicada al sector inmobiliario.

Diseño del estudio

Genesove & Mayer estudian el mercado condominial de **Boston** entre 1990 y 1997, un período caracterizado por una severa recesión post-boom inmobiliario. La base de datos incluye transacciones con precio de compra original observable —lo que permite calcular la pérdida nominal para cada vendedor.

Hallazgos principales

- Los propietarios que enfrentan una **pérdida nominal** (precio de mercado < precio de compra) fijan su precio de reserva sistemáticamente por encima del nivel competitivo
- Los coeficientes oscilan entre **25% y 35%** de la pérdida potencial: por cada $10,000 de pérdida no realizada, el precio de lista se eleva $2,500–$3,500
- Los propietarios en pérdida tienen **tiempos de permanencia en el mercado** significativamente mayores y probabilidades de venta menores

Implicación algorítmica contemporánea

La relevancia de Genesove & Mayer (2001) para el ecosistema PropTech actual es directa y multidimensional:

- Plataformas que muestran *"cambio respecto al precio inicial"* o *"días en el mercado"* construyen activamente el marco conductual de **reference dependence**
- Los AVMs que incorporan el precio listado como variable predictora heredan el sesgo del vendedor, generando circularidad valorativa
- Los portales que agregan historial de precios (Zillow, Homepty) crean puntos de referencia visibles que activan la aversión a la pérdida tanto en compradores como en vendedores

> "En un mercado inmobiliario mediado por AVMs, el precio es endógeno a las decisiones algorítmicas que lo estiman; el anclaje se convierte en un punto fijo dinámico del sistema." — González Tejeda (WP-2026-DVH); Homepty Hypergraph

§11 REGULACIÓN Y ÉTICA

El marco normativo emergente

La regulación algorítmica transita de principios éticos (OCDE 2019, UNESCO 2021) a instrumentos jurídicos vinculantes. La economía conductual proporciona el lenguaje técnico para identificar prácticas manipulativas en términos cognitivos —no sólo formales— lo que permite una tipificación más precisa y efectiva que el derecho del consumidor tradicional.

🇪🇺 AI Act (Reg. 2024/1689)

Art. 5.1(a) · Prohibiciones

Prohíbe sistemas de IA que desplieguen "técnicas subliminales, manipulativas o engañosas" dirigidas a distorsionar materialmente el comportamiento de una persona en forma que cause daño. Vigencia escalonada 2025–2027. Incluye sanciones de hasta 7% de la facturación global.

🇪🇺 Digital Services Act

Art. 25 · Interfaces online

Prohíbe a las plataformas diseñar, organizar u operar sus interfaces de manera que engañen, manipulen o distorsionen la capacidad de los usuarios para tomar decisiones libres e informadas. Aplica a VLOPs y VLOSEs (>45M usuarios en UE).

🇺🇸 FTC Act §5

"Unfair or deceptive acts"

La FTC ha publicado guías explícitas sobre dark patterns (2022) y ha sancionado casos (Epic Games, $520M en 2022) bajo la doctrina de prácticas desleales. Aplicable también a modelos generativos engañosos y sistemas de recomendación manipulativos.

🇧🇷 LGPD + Marco Legal IA

PL 2338/2023 — Brasil

Proyecto de Ley del Senado brasileño (aprobado dic. 2024) introduce categorías de riesgo y obligaciones de transparencia algorítmica alineadas con el AI Act europeo. Primera legislación integral de IA en América Latina.

🇫🇷 Loi SREN (2024)

Espacio digital francés

Tipifica explícitamente "patrones sombríos" (*design trompeur*) y otorga a la Arcom competencias de auditoría algorítmica. Marco pionero a nivel de Estado-miembro europeo, con enfoque en interfaces de plataformas de consumo masivo.

🇲🇽 LFPDPPP y LFPC

PROFECO + INAI — México

La Ley Federal de Protección al Consumidor sanciona prácticas comerciales abusivas; la LFPDPPP regula el tratamiento de datos. Aún sin régimen específico para manipulación algorítmica — **frontera regulatoria abierta** de alta relevancia para el ecosistema PropTech mexicano.

§12 APIS Y RECURSOS

Infraestructura de datos para investigación conductual-algorítmica

Un conjunto curado de APIs y repositorios útiles para ejercicios empíricos, replicaciones y trabajos de curso. Clasificados por costo de acceso y relevancia temática. La disponibilidad de datos abiertos ha reducido sustancialmente la barrera de entrada a la investigación empírica en economía conductual computacional.

Literatura científica y bibliometría

OpenAlex — gratis

Grafo bibliográfico abierto con >250M obras. Reemplazo libre de Microsoft Academic Graph. `api.openalex.org/works?search=prospect+theory`

Semantic Scholar — freemium

Corpus semántico de Allen AI. Útil para embeddings de papers y grafo de citaciones contextual. `api.semanticscholar.org/graph/v1/paper/search`

CrossRef — gratis

API canónica para resolver DOIs y metadatos bibliográficos. `api.crossref.org/works/{DOI}`

Comportamiento digital

Google Trends — gratis (no oficial)

Índice de atención pública. Útil para medir salience algorítmico ex post. `pytrends.TrendReq().build_payload(...)`

Wikipedia Pageviews — gratis

Vistas diarias por artículo; proxy de atención pública y salience. `wikimedia.org/api/rest_v1/metrics/pageviews/`

Datos macro y mercados

Banxico SIE — gratis · token

Sistema de Información Económica: IGAE, INPC, Encuesta de Expectativas, tasas, TC, SHF-IGEV. `banxico.org.mx/SieAPIRest/service/v1/series/{id}/datos`

INEGI API — gratis · token

Indicadores oficiales México: ENOE, ENCO, INPC, Censos. `inegi.org.mx/app/api/indicadores/`

FRED — API key gratis

>800,000 series económicas del St. Louis Fed; benchmark para ejercicios de descuento intertemporal. `api.stlouisfed.org/fred/series/observations`

Plataformas experimentales

Prolific / MTurk — costo por participante

Reclutamiento de muestras para experimentos online. Prolific es el estándar académico actual por calidad demográfica y transparencia.

oTree — open-source

Framework para experimentos de economía conductual. Integra con Heroku y AWS. `pip install otree`

OSF — gratis

Registro de preanálisis, datos abiertos, código de replicación. Estándar post-crisis de replicabilidad. `api.osf.io/v2/`

Bibliografía de referencia académica

Selección anotada en formato APA-7; DOIs verificables. El corpus cubre la teoría canónica (1955–2008) y el frente activo de investigación sobre economía conductual algorítmica (2015–2026). Se incluyen tanto los trabajos fundacionales —indispensables para comprender la arquitectura conceptual del campo— como los estudios más recientes que abordan la intersección entre algoritmos, conducta y regulación.

Fundamentos del programa conductual

- **Simon, H. A.** (1955). A behavioral model of rational choice. *QJE*, 69(1), 99–118. DOI: 10.2307/1884852
- **Tversky & Kahneman** (1974). Judgment under uncertainty: Heuristics and biases. *Science*, 185(4157), 1124–1131. DOI: 10.1126/science.185.4157.1124
- **Kahneman & Tversky** (1979). Prospect theory. *Econometrica*, 47(2), 263–291. DOI: 10.2307/1914185
- **Tversky & Kahneman** (1992). Advances in prospect theory: CPT. *J. Risk Uncertainty*, 5(4), 297–323. DOI: 10.1007/BF00122574
- **Laibson, D.** (1997). Golden eggs and hyperbolic discounting. *QJE*, 112(2), 443–477. DOI: 10.1162/003355397555253
- **Prelec, D.** (1998). The probability weighting function. *Econometrica*, 66(3), 497–527. DOI: 10.2307/2998573
- **Thaler, R. H., & Sunstein, C. R.** (2008). *Nudge*. Yale University Press.
- **Kahneman, D.** (2011). *Thinking, fast and slow*. Farrar, Straus and Giroux.
- **Gigerenzer, G.** (2008). Why heuristics work. *Perspectives on Psychological Science*, 3(1), 20–29. DOI: 10.1111/j.1745-6916.2008.00058.x

Aplicaciones en mercados e instituciones

- **Genesove & Mayer** (2001). Loss aversion and seller behavior. *QJE*, 116(4), 1233–1260. DOI: 10.1162/003355301753265561
- **Madrian & Shea** (2001). The power of suggestion: 401(k) inertia. *QJE*, 116(4), 1149–1187. DOI: 10.1162/003355301753265543
- **Thaler & Benartzi** (2004). Save More Tomorrow. *JPE*, 112(S1), S164–S187. DOI: 10.1086/380085
- **González Tejeda, L., & Adamuz** (2016). La demanda de vivienda en México. *El Trimestre Económico*, 83(332), 771–810.

Algoritmos, plataformas y conducta digital

- **Pariser, E.** (2011). *The filter bubble*. Penguin.
- **Mullainathan & Shafir** (2013). *Scarcity*. Times Books. DOI: 10.1126/science.1238041
- **Kramer, Guillory & Hancock** (2014). Emotional contagion through social networks. *PNAS*, 111(24), 8788–8790. DOI: 10.1073/pnas.1320040111
- **Bakshy, Messing & Adamic** (2015). Exposure to ideologically diverse news on Facebook. *Science*, 348(6239), 1130–1132. DOI: 10.1126/science.aaa1160
- **Yeung, K.** (2017). Hypernudge. *Information, Communication & Society*, 20(1), 118–136. DOI: 10.1080/1369118X.2016.1186713
- **Matz, Kosinski et al.** (2017). Psychological targeting. *PNAS*, 114(48), 12714–12719. DOI: 10.1073/pnas.1710966114
- **Sunstein, C. R.** (2017). *#Republic*. Princeton University Press.
- **Mathur et al.** (2019). Dark patterns at scale. *PACMHCI*, 3(CSCW). DOI: 10.1145/3359183
- **Allcott et al.** (2020). Welfare effects of social media. *AER*, 110(3), 629–676. DOI: 10.1257/aer.20190658
- **Luguri & Strahilevitz** (2021). Shining a light on dark patterns. *J. Legal Anal.*, 13(1), 43–109. DOI: 10.1093/jla/laaa006
- **DellaVigna & Linos** (2022). RCTs to scale. *Econometrica*, 90(1), 81–116. DOI: 10.3982/ECTA18709
- **González Tejeda, L., & Villalobos** (2026). The Homepty Hypergraph. WP-2026-STRAT-01. Homepty Research.

Regulación y marco normativo

- **Unión Europea** (2022). Digital Services Act — Reg. (UE) 2022/2065. *DOUE L 277/1*.
- **Unión Europea** (2024). AI Act — Reg. (UE) 2024/1689. *DOUE L*.
- **Narayanan et al.** (2020). Dark patterns: Past, present, and future. *Communications of the ACM*, 63(9), 42–47. DOI: 10.1145/3397884

SÍNTESIS DEL MÓDULO

Mapa conceptual del módulo: del sesgo a la regulación

El recorrido del módulo sigue una lógica integrada que va desde los fundamentos cognitivos de la decisión hasta sus consecuencias regulatorias en el ecosistema digital. Los tres niveles de análisis —teórico, empírico y normativo— son inseparables: la política pública sin fundamento conductual es ciega; la teoría sin evidencia de campo es optimista; la regulación sin comprensión técnica de los algoritmos es ineficaz.

Preguntas centrales sin resolver

- ¿Qué estructura matemática preserva la autonomía decisional cuando el entorno de elección es endógeno al comportamiento pasado del agente?
- ¿Cuál es la frontera normativa entre personalización legítima y manipulación algorítmica?
- ¿Cómo diseñar auditorías algorítmicas que sean técnicamente feasibles y jurídicamente vinculantes?

Agenda de investigación — Behavioral Econ × AlgoGov

- Calibración de λ en contextos de alta asimetría informacional (mercados inmobiliarios, financieros, salud)
- Medición del efecto de los AVMs sobre el anclaje en mercados latinoamericanos
- Diseño de contrafactuales para evaluar dark patterns bajo DSA y AI Act
- Integración de modelos β-δ en arquitecturas de recomendación con restricciones de bienestar

Fin del módulo

Material docente preparado para el módulo especial de Economía Conductual del programa de posgrado del ITESM, Campus Santa Fe. Integra formalización matemática, evidencia empírica y un corpus bibliográfico verificable con DOIs. Se distribuye bajo licencia Creative Commons BY-NC-SA 4.0 para uso docente y de investigación.

Citar como

González Tejeda, L. (2026). *Economía conductual en el ecosistema algorítmico*. Material docente ITESM · Homepty Research Series. DOI: 10.homepty/BE-ALGO-2026.01

Afiliaciones

ITESM · Campus Santa Fe · EGADE Business School · Homepty Research

Información del módulo

- **Serie:** Lecturas computacionales avanzadas · Vol. I · Ed. 2026
- **Campo:** Behavioral Econ × AlgoGov
- **Licencia:** CC BY-NC-SA 4.0 — uso docente y de investigación
- **DOI:** 10.homepty/BE-ALGO-2026.01

© 2026 · DR. LEONARDO GONZÁLEZ TEJEDA | ITESM · CAMPUS SANTA FE · CDMX | CC BY-NC-SA 4.0