

# Simulación Monte Carlo y Cadenas de Markov

MÓDULO 4

FEB-JUN 2026

Técnicas computacionales avanzadas para modelar fenómenos sociales.  
Concentración en Economía Aplicada y Ciencia de Datos, ITESM-SF, Ciudad de México.



# Método de Monte Carlo: Fundamentos

## Idea Central

Método estadístico para calcular el área bajo una curva mediante simulación. Es una solución probabilística al problema de integración numérica.

Supongamos que existe  $M > 0$  tal que  $0 \leq f(\theta) \leq M$  para todo  $\theta \in [a, b]$ . Queremos calcular la integral:

$$I = \int_a^b f(\theta) d\theta$$

El valor de la integral corresponde al área bajo la curva  $\phi = f(\theta)$  para  $\theta \in [a, b]$ , inscrita en el rectángulo  $R = [a, b] \times [0, M]$ .

# Estimación por Monte Carlo

La función de densidad de una distribución uniforme sobre el rectángulo R se define como:

$$p(\theta, \phi) = \frac{1}{M(b-a)} I_R(\theta, \phi)$$

## Simulación

Se genera una muestra  $(\theta_1, \phi_1), \dots, (\theta_n, \phi_n)$  de  $p(\theta, \phi)$

## Conteo

Se cuentan cuántos valores caen bajo la curva  $\phi = f(\theta)$

## Estimador

El estimador  $\hat{I}$  obtenido es insesgado de  $I$

La varianza del estimador está dada por:

$$\text{Var}(\hat{I}) = \frac{1}{N} \{M(b-a) - I\}$$

# Cálculo de $\pi$ por Monte Carlo




Diagrama mostrando un cuadrado de lado 2 que contiene un círculo de radio 1. Área del cuadrado = 4, Área del círculo =  $\pi$ .

La relación entre las áreas se expresa como:

$$\frac{\text{Área del círculo}}{\text{Área del cuadrado}} = \frac{\pi(1)^2}{4} = \frac{\pi}{4}$$

Esto puede describirse mediante la integral:

$$\int_0^1 \sqrt{1-x^2} dx = \frac{\pi}{4}$$

Se generan parejas aleatorias  $(x_r, y_r)$  distribuidas uniformemente entre 0 y 1, contando cuántos puntos caen dentro del círculo:  $y_r^2 + x_r^2 \leq 1$

# Convergencia del Método Monte Carlo

La gráfica ilustra cómo el valor estimado de  $\pi$  converge al valor real (línea roja punteada  $\approx 3.14159$ ) conforme aumenta el número de iteraciones  $N$ . Las fluctuaciones iniciales disminuyen significativamente después de 100,000 iteraciones.

3.14

$N = 100,000$

Primera aproximación  
estable

3.1415


$N = 600,000$

Convergencia mejorada

3.1415

$N = 1,000,000$

Estimación final precisa



# Inferencia Bayesiana y MCMC

En un contexto bayesiano con modelo muestral  $Y \sim p(y|\theta)$  y distribución inicial  $p(\theta)$ , la distribución posterior se calcula:

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{\int p(\theta')p(y|\theta')d\theta'}$$

01

## Desafío Computacional

El cálculo analítico de  $p(\theta|y)$  es complicado en la mayoría de los casos, incluso descartando el denominador como factor de escalamiento.

02

## Técnicas Alternativas

Existen métodos como aproximación de Laplace y cuadratura, pero las técnicas MCMC son las más utilizadas por la capacidad de cómputo disponible.

03

## Idea de MCMC

Construir una cadena de Markov fácil de simular mediante muestreo, cuya distribución de equilibrio corresponda a la distribución posterior de interés.

# Cadenas de Markov: Definición y Ejemplo

📄 **Definición:** Proceso estocástico discreto con estados finitos que cumple la propiedad de Markov:

$$P(X_{t+1} = s | X_1 = s_1, \dots, X_t = s_t) = P(X_{t+1} = s | X_t = s_t)$$


## Estados del Sistema

- **d:** Dormitorio
- **b:** Bar
- **c:** Comedor




Las aristas representan probabilidades de transición entre estados. Por ejemplo, la probabilidad de permanecer en el dormitorio es:

$$P(X_{t+1} = d \mid X_t = d) = 0.7$$



# Matriz de Transición y Dinámica



Las probabilidades de transición se representan matricialmente con entradas  $p_{i,j} \equiv P(X_{t+1} = i \mid X_t = j)$ :

$$T = \begin{bmatrix} 0.7 & 0.4 & 0.2 \\ 0.1 & 0.4 & 0.2 \\ 0.2 & 0.2 & 0.6 \end{bmatrix}$$

La dinámica de la distribución de probabilidad se expresa como:

$$P(X_{t+1}) = TP(X_t)$$

Si el pasajero está en el dormitorio al tiempo  $t=0$ , entonces  $P(X_0) = [1, 0, 0]^T$ . Al tiempo siguiente:  $P(X_1) = TP_0 = [0.7, 0.1, 0.2]^T$ . Para tiempos futuros:  $P_t = T^t P_0$



# Teorema Perron-Frobenius y Algoritmo Metropolis

1

## Conjunto Finito

Estados  $S = \{1, 2, \dots, K\}$

2

## Transición Fija

Matriz no cambia en el tiempo

3

## Ergodicidad

Accesibilidad entre todos los estados

4

## No Ciclicidad

Sin ciclos repetitivos de estados

El algoritmo de Metropolis construye una cadena donde la distribución propuesta  $q(\cdot|x_{n-1})$  cambia con el tiempo. Generar una nueva muestra depende del estado previo. El valor de aceptación se calcula como:

$$\alpha(x|x_{n-1}) = \min \left\{ 1, \frac{p(x)}{p(x_{n-1})} \right\}$$

Si  $u \sim U(0,1)$  y  $u \leq \alpha(x|x_{n-1})$ , entonces  $x_n = x$ ; de lo contrario,  $x_n = x_{n-1}$ .

# Ejemplo: Distribución Normal con Varianza Conocida

Sea  $\theta \sim \text{normal}(\mu, \tau^2)$  y  $\{y_1, \dots, y_n \mid \theta\} \sim \text{i.i.d. normal}(\theta, \sigma^2)$ . La distribución posterior de  $\theta$  es  $\text{normal}(\mu_n, \tau_n^2)$  donde:

$$\mu_n = \bar{y} \frac{\frac{n}{\sigma^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}} + \mu \frac{\frac{1}{\tau^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$
$$\tau_n^2 = \frac{1}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

## Parámetros del Ejemplo

- $\sigma^2 = 1, \tau^2 = 10, \mu = 5, n = 5$
- $y = \{9, 37, 10, 18, 9, 16, 11, 60, 10, 33\}$
- Resultado:  $\mu_n = 10.03, \tau_n^2 = 0.2$
- $p(\theta|y) = \text{dnorm}(10.03, 0.44)$

## Proporción de Aceptación

Para estabilidad numérica, se calcula  $\log r$ :

$$\log r = \sum_{i=1}^n [\log \text{dnorm}(y_i, \theta^*, \sigma) - \log \text{dnorm}(y_i, \theta^{(s)}, \sigma)] + \log \text{dnorm}(\theta^*, \mu, \tau) - \log \text{dnorm}(\theta^{(s)}, \mu, \tau)$$

El valor propuesto se acepta si  $\log u < \log r$ .